

신정호

헬스케어 AI 프로젝트 · 데이터 분석에서 LLM 백엔드까지

미니 데이터 분석에서 시작해 ML 해커톤을 거쳐, 운영을 염두에 둔 LLM 백엔드까지 만들어 봤습니다. 헬스케어·의료 도메인에서 다루는 범위를 한 단계씩 넓혀왔고, 분석의 엄밀함과 백엔드 쪽 실행을 둘 다 해본 게 강점입니다.

github.com/DrunkPooh · 오즈코딩스쿨(넥스트러너스) AI 트랙 · top03010@naver.com

성장 서사 — 의료 도메인에서 난이도를 올려왔습니다

2026.01	2026.02	2026.04	2026.05~06
흡연 여부 분석	칼로리 소모 예측	난임 성공 예측	MediPT
EDA · 통계 검정	회귀 · 팀원	분류 · 팀장	풀스택 LLM · 팀장

시점	프로젝트 · 유형	핵심 결과	역할
2026.01	흡연 여부 분석 · EDA·통계	가설 3건 통계 검정 전부 $p<0.001$	데이터 분석
2026.02	칼로리 소모 예측 · 회귀	RMSE 0.857 → 0.204 (-76%)	팀원
2026.04	난임 임신 성공 예측 · 분류	Public LB 0.74218 (1위와 0.0003차)	팀장
2026.05~06	MediPT · 풀스택 LLM	동시성 99× · 캐싱으로 외부 API 장애 격리 · PR 139	팀장 (BE-B)

99×

동시성 개선 (3.3 → 331
req/s)

580→7ms

약품검색 중앙값 (캐시 히트)

3.25→4.5

LLM 안전성 / 5 (as-judge)

139

누적 머지 PR (CI · Codecov)

왜 만들었나

처방전을 받아도 복용법이나 부작용을 제대로 이해하고 나오는 사람은 많지 않습니다. 약을 여러 개 같이 먹는 고령자·만성질환자는 더 그렇고요. 처방전을 사진으로 올리면 약품을 자동으로 읽고, 나이·체중·알레르기·질환 같은 프로필을 합쳐 복약 안내와 생활습관 가이드를 만들어주는 서비스를 팀으로 만들었습니다. 저는 백엔드 B를 맡아 약품 연동·안전 응답·챗봇·성능을 담당했습니다.

어떻게 풀었나

가장 신경 쓴 건 외부 의존성이었습니다. 약품 검색은 식약처 공공 API를 매번 호출하는데, 느려지거나 죽으면 우리 서비스도 같이 멈춥니다. 그래서 검색 결과를 Redis에 캐싱했습니다. 캐시에 있으면 외부에 아예 안 부르고 인메모리에서 바로 응답합니다. 중앙값이 580ms에서 7ms로 떨어졌는데, 숫자보다 중요한 게 따로 있었습니다. 식약처 API가 503으로 죽은 상황을 가정해도 한 번이라도 캐싱된 검색어는 정상 응답한다는 걸 테스트로 증명했습니다(PR #184). 속도 개선이 라기보다 장애 격리에 가깝습니다.

성능 쪽에선 동기로 돌던 LLM 호출이 이벤트 루프를 막고 있었습니다. async로 바꾸고 ARQ 백그라운드로 넘기니 동시 100건 처리량이 초당 3.3건에서 331건으로 올랐습니다(locust 측정). 챗봇은 의료 도메인이라 위험한 질문에 잘못 답하면 안 됩니다. 처음엔 키워드 필터 하나로 막았는데 놓치거나 과하게 막는 경우가 생겨, 1차에서 놓친 걸 문맥으로 다시 보는 2단계 분류를 붙였고 안전성 점수가 3.25에서 4.5로 올랐습니다. RAG는 별도 실험(#171)으로 임베딩 검색과 프롬프트 전체 주입을 비교했는데, 품질은 거의 같으면서(4.98/5.0) 토큰을 73.6% 아낄 수 있어 챗봇에 임베딩 코사인 유사도 검색으로 연동했습니다. 모델은 gpt-4o-mini, 임베딩은 text-embedding-3-small을 썼고, 키가 mini까지만 열려 모델을 키우는 대신 프롬프트와 안전필터로 품질을 받쳤습니다.

솔직한 시행착오

성능을 처음 잴 때 P95가 7초쯤 나왔습니다. 멘토님이 "웹 검색이 7초는 비현실적"이라고 짚으셨고, 다시 보니 API 키가 더미값이라 거부된 요청이 타임아웃까지 늘어진 비정상값이었습니다. 진짜 키로 같은 조건(8명/60초)에서 다시 잴 땐 캐시 미스 P95 2초, 캐시 히트 12ms로 나왔습니다. 틀린 수치를 그대로 들고 갔으면 더 크게 깨졌을 겁니다. 측정은 환경부터 의심해야 한다는 걸 이때 배웠습니다.

FastAPI · Python 3.14 · Tortoise ORM · PostgreSQL 16 · Redis · ARQ · OpenAI gpt-4o-mini · text-embedding-3-small · 식약처 OpenAPI · Docker · GitHub Actions · Codecov

0.74218팀 Public LB (1위와 0.0003
차)**25.6만**

학습 데이터 (69 features)

3-modelLightGBM 앙상블 + rank
avg**26%**

양성 비율 (불균형)

맥락

난임 시술 환자의 임신 성공 여부를 맞추는 해커톤이었습니다. 25만 건이 넘는 데이터에 피쳐 69개, 양성이 26%인 불균형 문제였고 지표는 ROC-AUC. 6일짜리 단기전이라 Public LB 점수로 자동 best가 채택되는 룰이었습니다. 3인 팀 팀장으로 모델 전략과 제출 결정을 맡았습니다.

어떻게 풀었나

LightGBM 모델 3개를 일부터 다르게 만들었습니다. num_leaves를 31/63/95, seed를 42/2024/777로 바꿔 서로 조금씩 다른 모델을 StratifiedKFold 5겹으로 학습하고, 평균 낸 뒤 rank averaging으로 합쳤습니다. 점수가 0.0001 단위로 갈리는 싸움이라 한 곳 차이가 컸습니다. leakage가 제일 무서웠습니다. categorical 매핑이나 결측 보정을 전체 데이터로 fit하면 test 정보가 새기 때문에, fold의 train 부분으로만 fit하고 test엔 적용만 했습니다. Adversarial Validation으로 train/test 분포가 갈리는지 봤고, OOF와 LB 갭을 계속 보면서 과적합된 제출은 걸렸습니다.

결과 · 배운 점

팀 최종 Public LB 0.74218. 1위가 0.74246였으니 0.0003 차이였습니다. 제 단일 모델(0.74201)보다 팀 앙상블이 있었는데, 이게 핵심이었습니다. OOF가 좋아진다고 LB가 따라오는 게 아니라는 걸 몇 번 데이고 알았습니다. train fit으로 부풀려진 모델을 골라내는 게 점수를 지키는 일이었습니다. DART/GOSS, CatBoost, MLP, Target Encoding, Pseudo Labeling은 기대보다 효과가 없었는데, 안 된 것도 다 기록으로 남겼습니다.

LightGBM · scikit-learn · StratifiedKFold 5-fold · rank averaging · Adversarial Validation · OOF 분석

0.857→0.204

Validation RMSE (−76%)

15K/7.5K

Train / Test 샘플

v18→v24

6+ 버전 반복

2-Stage

+ Shift Optimization

맥락

운동 데이터로 칼로리 소모량을 맞추는 회귀 문제. 정수 RMSE가 지표였습니다. 처음엔 피처를 30개 넘게 늘리고 2단 스택킹을 쌓는, 혼한 방향으로 갔습니다.

어떻게 풀었나 (한 번 크게 옳었습니다)

log1p로 학습했을 때 OOF RMSE가 0.0236으로 아주 좋게 나왔습니다. 믿고 갔는데, expm1로 되돌릴 때 고칼로리 구간 오차가 확 튀면서 Public LB가 오히려 망가졌습니다(v18 0.886 → v19 4.06). 이 부분이 제일 까다로웠습니다. 결국 log 변환을 버리고 raw target으로 다시 학습했습니다.

상관을 보니 Duration × Heart_Rate가 칼로리를 거의 결정해서 "운동총량" 파생변수를 만들었고, Stage 1에서 강한 선형 변수를 처리하고 Stage 2에서 신체 조건으로 오차를 보정하는 2단 구조에 Ridge 메타모델을 얹었습니다. 마지막엔 정수 RMSE라는 지표 특성을 직접 노렸습니다. round 경계에서 손해 보는 걸 줄이려고 shift를 −0.49 ~ +0.49까지 0.001씩 옮겨가며 가장 나은 지점을 찾았습니다.

결과 · 배운 점

Validation RMSE가 0.857에서 0.204로 내려갔습니다. 복잡하게 쌓은 스택킹이 아니라, 지표를 제대로 이해하고 거기에 맞춘 게 점수를 만들었습니다. 복잡한 게 항상 좋은 건 아니라는 걸 이 프로젝트로 확실히 느꼈습니다.

Python · scikit-learn · Ridge Stacking · 2-Stage 모델링 · OOF Shift Optimization · 후처리 라운딩

가설 3건

t-test · Mann-Whitney U

 $p < 0.001$

전 가설 유의

7,000명

건강검진 데이터 (17지표)

5.61 vs 4.79

TG/HDL 흡연 vs 비흡연

맥락

흡연 여부를 직접 묻는 건 현실적으로 어렵습니다. 그래서 건강검진 데이터(나이·BMI·공복혈당·혈압·중성지방·콜레스테롤 등)로 흡연자와 비흡연자의 지표 차이가 통계적으로 유의한지 검증했습니다. 7천 명, 17개 지표. 저는 가설을 세우고 검정하는 파트를 맡았습니다.

어떻게 풀었나

가설 세 개를 세웠습니다. 핵심은 교란 변수였습니다. 흡연자가 지표가 나빠 보여도 그게 체형 때문일 수 있으니, BMI를 정상 범위로 고정해놓고 봤습니다. 정상 BMI 흡연자의 TG/HDL 비율이 비흡연자보다 높은지 t-test로 봤더니 5.61 대 4.79, $t=6.96$, $p < 0.001$. BMI 군별 헤모글로빈/간효소 분포 차이는 Mann-Whitney U로 봤고 모든 군에서 $p < 0.001$. 정상 BMI 흡연자의 크레아티닌(로그변환)도 t-test에서 유의했습니다. 정규성 여부에 따라 t-test와 Mann-Whitney U를 갈라 썼습니다.

결과 · 배운 점

가설 3건 모두 $p < 0.001$ 로 유의했습니다. "겉보기엔 정상 체중인데 대사 지표는 위험한" 패턴이 흡연자에서 보였습니다. 체형을 통제해도 흡연 신호가 일관되게 남는다는 게 의미 있었습니다. 데이터를 그냥 돌리기 전에 뭐가 진짜 차이를 만드는지부터 의심하는 습관이 여기서 생겼습니다.

Python · pandas · t-test · Mann-Whitney U · seaborn · 파생변수 · 로그변환

기술 스택 · 핵심 역량 종합

언어 / ML	Python · scikit-learn · LightGBM · XGBoost · CatBoost · pandas
백엔드	FastAPI · Tortoise ORM · ARQ(비동기 워커) · Redis · PostgreSQL 16
LLM / AI	OpenAI gpt-4o-mini · text-embedding-3-small · RAG(임베딩 코사인 유사도) · LLM-as-judge 평가
인프라 / 협업	Docker · GitHub Actions · Codecov · Git Flow + PR 리뷰
방법론	통계적 가설 검정 · 정량 성능 측정(locust) · Adversarial Validation · OOF 후처리 보정

핵심 역량 요약

- ✓ 헬스케어 데이터 분석에서 ML 해커톤, 풀스택 LLM 백엔드까지 의료 도메인에서 분석과 엔지니어링을 모두 경험했습니다.
- ✓ 난임 예측 해커톤에서 팀장으로 LightGBM 3-model 앙상블을 설계해 Public LB 0.74218(1위와 0.0003차)을 기록하고, OOF와 LB 갭 분석으로 과적합을 방어했습니다.
- ✓ 칼로리 예측에서는 복잡한 앙상블 대신 정수 RMSE라는 지표 특성을 직접 노려 RMSE를 0.857에서 0.204로 줄였습니다.
- ✓ 흡연 데이터 분석에서 가설 3건을 통계 검정으로 모두 유의하게($p < 0.001$) 입증하고, 교란 변수까지 통제했습니다.
- ✓ MediPT에서는 비동기 전환으로 처리량을 99배 올리고, Redis 캐싱으로 외부 API 장애를 격리했으며, LLM 응답을 LLM-as-judge로 정량 평가·개선했습니다.

분석의 엄밀함과 엔지니어링의 실행력을 함께 갖춘 사람

제약·바이오 QC 실무에서 익힌 기준 준수와 데이터 정확성을, 의료 AI 프로젝트의 정량적 검증으로 이어갑니다.